PRÉDICTION DU RISQUE DE DÉFAUT DE CRÉDIT

Étude comparative de la régression logistique et de LightGBM

Projet de Data Science — Home Credit Default Risk

Rapport de fin de projet | Octobre 2026

SYNTHÈSE EXÉCUTIVE

Ce projet porte sur la prédiction du risque de défaut de crédit à partir des données du jeu *Home Credit Default Risk*, mis à disposition sur Kaggle.

L'objectif était de construire et de comparer deux modèles de classification supervisée — une régression logistique et LightGBM — afin d'évaluer leur capacité à identifier les clients présentant un risque élevé de difficultés de remboursement.

L'étude a été organisée autour d'une démarche d'enrichissement progressif des données. Cinq configurations ont été successivement évaluées, avec un nombre de variables passant de 3 à 20.

Les résultats mettent en évidence trois constats majeurs :

- **L'enrichissement des données améliore les performances prédictives** des deux algorithmes.
- **LightGBM obtient systématiquement une meilleure ROC-AUC** que la régression logistique.
- **Les variables `EXT_SOURCE` apportent le gain de performance le plus important** de l'expérimentation.

La meilleure configuration, composée de 20 variables et utilisant LightGBM, atteint une **ROC-AUC de 0,7443** et une **Average Precision de 0,2257** sur l'ensemble de validation.

Ces résultats démontrent l'intérêt de combiner différentes sources d'informations pour améliorer l'évaluation du risque de crédit, tout en soulignant les limites qui doivent être prises en compte avant toute utilisation opérationnelle.

---

1. CONTEXTE ET OBJECTIFS DU PROJET

1.1. Contexte

L'octroi de crédit constitue une activité centrale pour les établissements financiers. Il nécessite d'évaluer la capacité des demandeurs à respecter leurs engagements de remboursement.

Une mauvaise estimation du risque peut entraîner des conséquences importantes.

L'acceptation d'un dossier présentant un risque élevé expose l'établissement prêteur à des pertes financières. À l'inverse, le refus d'un dossier présentant un risque faible peut priver un client d'un financement et représenter une opportunité commerciale perdue.

Les modèles de *credit scoring* cherchent à faciliter cette prise de décision en attribuant aux clients un score reflétant leur niveau de risque estimé.

Le jeu de données **Home Credit Default Risk** fournit un cadre permettant d'étudier cette problématique à partir de plusieurs catégories d'informations : caractéristiques des demandeurs, historique de crédit, demandes de financement précédentes et comportement de remboursement.

1.2. Problématique

La problématique retenue est la suivante :

Dans quelle mesure l'enrichissement progressif des données améliore-t-il la prédiction du risque de défaut de crédit, et lequel des deux algorithmes — régression logistique ou LightGBM — présente les meilleures performances ?

Cette question conduit à étudier simultanément deux dimensions :

- L'influence des informations utilisées pour entraîner les modèles.
- L'influence de l'algorithme choisi sur les performances prédictives.

1.3. Objectifs

Le projet poursuit quatre objectifs principaux :

1. Explorer les caractéristiques des demandeurs et la distribution des situations de défaut.
2. Construire des variables explicatives à partir de plusieurs sources de données.
3. Comparer les performances d'une régression logistique et de LightGBM dans un protocole commun.
4. Identifier la configuration présentant la meilleure capacité de discrimination, puis examiner les facteurs contribuant à ses prédictions.

---

2. PRÉSENTATION DES DONNÉES

2.1. Jeu de données principal

L'analyse repose sur le jeu de données d'entraînement de Home Credit, qui contient **307 511 observations**.

Chaque observation correspond à un demandeur de crédit identifié par la variable `SK_ID_CURR`.

La variable cible est `TARGET`, définie de manière binaire :

- **TARGET = 0** : absence de difficultés de paiement au sens de la cible du jeu de données.
- **TARGET = 1** : présence de difficultés de paiement au sens de cette même cible.

La proportion d'observations positives est d'environ **8,07 %**, contre 91,93 % d'observations négatives.

Le problème présente donc un **déséquilibre important entre les classes**.

Cette caractéristique justifie de ne pas utiliser l'accuracy comme indicateur principal. Un modèle prédisant systématiquement la classe majoritaire pourrait obtenir une accuracy élevée sans identifier correctement les clients présentant un risque de défaut.

2.2. Sources de données

Quatre ensembles de données ont été mobilisés :

Application Train

Il contient les informations relatives aux demandeurs, notamment certaines caractéristiques personnelles et financières.

Bureau

Il fournit des informations sur les crédits enregistrés dans les historiques des organismes de crédit.

Previous Application

Il permet d'étudier les demandes de financement précédemment déposées par les clients.

Installments Payments

Il renseigne les comportements de remboursement associés à des échéances de paiement.

Trois variables complémentaires, `EXT_SOURCE_1`, `EXT_SOURCE_2` et `EXT_SOURCE_3`, ont également été intégrées dans la dernière configuration. Ces variables proviennent du fichier `application_train.csv`, mais ont volontairement été réservées à la dernière étape afin de mesurer leur apport.

2.3. Construction des variables

Les informations issues des tables historiques ont été agrégées au niveau de chaque demandeur, afin de conserver une observation par client.

Les variables construites comprennent notamment :

- L'âge du demandeur (`AGE`).
- Le logarithme du revenu (`LOG_INCOME`).
- Une approximation du ratio d'endettement (`DTI_approx`).
- Des indicateurs décrivant les crédits enregistrés dans Bureau.
- Le nombre de demandes de financement précédentes.
- Le nombre de demandes refusées.
- Des indicateurs relatifs aux retards de paiement.

L'enrichissement a été réalisé en cinq étapes.

Étape	Configuration	Nombre de variables
M0	Informations Application	3
M1	Application + Bureau	9
M2	Ajout de Previous Application	13
M3	Ajout de Installments Payments	17

M4	Ajout des trois variables EXT_SOURCE	20

Cette organisation permet d'observer les changements de performance à mesure que de nouvelles informations sont introduites.

---

3. MÉTHODOLOGIE DE MODÉLISATION

3.1. Séparation des données

Afin de limiter le risque de surapprentissage, les données ont été réparties en trois ensembles stratifiés :

Ensemble	Nombre de clients	Proportion
Entraînement	184 506	60 %
Validation	61 502	20 %
Test	61 503	20 %

La stratification permet de conserver une proportion de clients en difficulté de paiement similaire entre les différents ensembles.

Les mêmes identifiants ont été conservés tout au long des configurations M0 à M4, assurant ainsi une comparaison cohérente des modèles.

3.2. Algorithmes comparés

Régression logistique

La régression logistique constitue une méthode classique de classification binaire.

Elle présente plusieurs avantages :

- Un fonctionnement relativement simple.
- Une interprétation possible des coefficients.
- Une mise en œuvre et une maintenance généralement moins complexes.

Dans ce projet, elle a été intégrée dans un pipeline comprenant l'imputation des valeurs manquantes et la standardisation des variables.

Les hyperparamètres ont été optimisés à l'aide de `GridSearchCV`.

LightGBM

LightGBM est un algorithme d'apprentissage supervisé reposant sur des ensembles d'arbres de décision entraînés par *gradient boosting*.

Il peut notamment exploiter des relations non linéaires et des interactions entre variables.

Ses hyperparamètres ont été optimisés avec `RandomizedSearchCV`.

L'utilisation de ces deux algorithmes permet de comparer une approche statistique relativement simple à une méthode d'apprentissage plus flexible.

3.3. Validation croisée et métriques

L'optimisation repose sur une validation croisée stratifiée à trois plis.

La **ROC-AUC** a été retenue comme métrique principale pour sélectionner les meilleurs hyperparamètres.

Elle mesure la capacité d'un modèle à attribuer un score de risque supérieur à un client en défaut plutôt qu'à un client sans défaut.

Une ROC-AUC de 0,5 correspond à une capacité de classement équivalente au hasard, tandis qu'une valeur de 1 représente une discrimination parfaite.

L'**Average Precision** a été utilisée comme métrique secondaire.

Elle complète la ROC-AUC dans ce contexte où les clients présentant des difficultés de paiement représentent une minorité de la population.

---

4. RÉSULTATS DE LA COMPARAISON PROGRESSIVE

4.1. Performances sur l'ensemble de validation

Le tableau suivant présente les résultats obtenus pour les cinq configurations.

Configuration	ROC-AUC Régression logistique	ROC-AUC LightGBM
M0 — Application	0,5888	0,5975
M1 — Bureau	0,6185	0,6290
M2 — Previous	0,6391	0,6503
M3 — Installments	0,6518	0,6638
M4 — EXT_SOURCE	**0,7338**	**0,7443**

Les performances augmentent progressivement lorsque de nouvelles variables sont ajoutées.

Pour la régression logistique, la ROC-AUC passe de **0,5888 à 0,7338**, soit un gain de 0,1450.

Pour LightGBM, elle passe de **0,5975 à 0,7443**, soit un gain de 0,1468.

Ces résultats mettent en évidence l'importance de l'enrichissement des informations disponibles pour la prédiction du risque de crédit.

Ils montrent également que **LightGBM obtient une meilleure ROC-AUC à chaque étape**.

4.2. Contribution des enrichissements

L'évolution de la ROC-AUC de LightGBM permet de mesurer le gain associé à chaque nouvelle configuration.

Enrichissement	Gain de ROC-AUC
Application → Bureau	+0,0315
Bureau → Previous	+0,0213
Previous → Installments	+0,0135
Installments → EXT_SOURCE	**+0,0805**

L'ajout des variables `EXT_SOURCE` représente le gain le plus important de l'expérimentation.

La ROC-AUC de LightGBM progresse de **0,6638 à 0,7443**, soit une augmentation de 0,0805.

Cela montre que ces trois variables contiennent une information prédictive particulièrement utile dans le cadre de cette expérience.

Il convient toutefois de préciser que les hyperparamètres ont été réoptimisés à chaque étape. Les gains observés correspondent donc à l'évolution des performances des modèles réoptimisés, et non à une mesure causale de l'effet de chaque variable.

4.3. Comparaison des configurations finales

La configuration M4 constitue la meilleure configuration observée pour les deux algorithmes.

Indicateur	Régression logistique	LightGBM
ROC-AUC validation	0,7338	**0,7443**
Average Precision validation	0,2083	**0,2257**

LightGBM surpasse la régression logistique de **0,0105 point de ROC-AUC**.

Son Average Precision est également supérieure.

Cette dernière atteint 0,2257, dans une population où la fréquence de la classe positive est d'environ 0,0807.

La performance obtenue confirme que le modèle produit un classement plus informatif que celui d'une méthode aléatoire, même si ses prédictions restent imparfaites.

LightGBM est donc retenu comme meilleur modèle selon le critère principal de l'étude : la ROC-AUC sur validation.

---

5. INTERPRÉTATION DU MODÈLE RETENU

5.1. Importance des variables

L'analyse de l'importance des variables de LightGBM a été réalisée à partir du gain associé aux divisions effectuées par les arbres de décision.

Les trois variables les plus importantes sont :

Variable	Importance relative
EXT_SOURCE_3	33,50 %
EXT_SOURCE_2	27,23 %
EXT_SOURCE_1	11,55 %
Total des trois variables	**72,28 %**

À elles seules, les trois variables `EXT_SOURCE` représentent **72,28 % de l'importance calculée selon le gain**.

Cette observation est cohérente avec l'amélioration importante de la ROC-AUC lors du passage de M3 à M4.

Les autres variables, notamment l'âge, les retards de paiement et certaines caractéristiques financières, contribuent également aux prédictions du modèle.

L'importance par gain doit néanmoins être interprétée avec prudence. Elle décrit la manière dont LightGBM utilise les variables, mais ne mesure ni leur effet causal sur le défaut ni leur contribution indépendante lorsque plusieurs variables sont corrélées.

5.2. Gestion des valeurs manquantes

Les scores externes présentent des proportions de valeurs manquantes différentes.

En particulier, `EXT_SOURCE_1` comporte environ **56,38 % de valeurs manquantes**.

Malgré cette proportion élevée, cette variable conserve une importance notable dans le modèle final.

Ce constat illustre l'intérêt d'une approche capable d'exploiter des variables incomplètes lorsque leur contenu reste informatif.

Il ne signifie toutefois pas que toutes les valeurs manquantes sont sans conséquence : leur fréquence, leur origine et leur éventuel caractère informatif doivent être examinés.

---

6. ÉVALUATION OPÉRATIONNELLE DU SCORING

La ROC-AUC permet d'apprécier la qualité globale du classement des clients, mais ne suffit pas à déterminer si un modèle est prêt pour une utilisation bancaire.

Une évaluation complémentaire peut notamment reposer sur trois analyses.

6.1. Concentration des défauts

Le **Lift@10 %** compare le taux de défaut des 10 % de clients considérés comme les plus risqués au taux moyen de la population.

Le **Capture@10 %** mesure la proportion de l'ensemble des défauts observés dans ce même groupe.

Ces indicateurs permettent de traduire les performances statistiques du modèle en termes de concentration du risque.

6.2. Analyse par déciles

Les clients peuvent être répartis en dix groupes de taille comparable, classés selon leur score de risque.

Dans le classement retenu :

- Le décile 1 contient les 10 % de clients ayant les scores les plus élevés.
- Le décile 10 contient les 10 % ayant les scores les plus faibles.

L'analyse du taux de défaut observé dans chaque décile permet d'examiner la capacité du modèle à différencier les groupes de risque.

6.3. Calibration et robustesse

L'étude de la calibration vise à vérifier si les probabilités prédites correspondent aux fréquences réelles de défaut.

Une analyse bootstrap appariée peut également être utilisée pour apprécier l'incertitude autour de la différence de ROC-AUC entre LightGBM et la régression logistique.

Limite des résultats disponibles : ces analyses complémentaires ont été proposées au cours du projet, mais les résultats numériques correspondants ne figurent pas dans la dernière

version du notebook transmise pour ce rapport. Ils ne sont donc pas présentés comme des résultats effectivement mesurés.

---

7. LIMITES DE L'ÉTUDE

Malgré les résultats obtenus, plusieurs limites méthodologiques doivent être prises en compte.

7.1. Déséquilibre des classes

La classe positive représente environ 8 % des observations.

Ce déséquilibre rend nécessaire l'utilisation d'indicateurs adaptés et complique la sélection éventuelle d'un seuil de décision.

7.2. Utilisation répétée de la validation

Les différentes configurations M0 à M4 ont été comparées sur le même ensemble de validation.

Cette démarche permet une comparaison cohérente, mais la sélection du modèle final à partir de ces résultats peut conduire à une estimation légèrement optimiste de sa performance future.

Les scores de validation croisée utilisés pour sélectionner les hyperparamètres ne constituent pas non plus des estimations issues d'une validation croisée imbriquée.

7.3. Indépendance du jeu de test

Un ensemble de test distinct a été constitué.

Cependant, cet ensemble avait déjà été consulté au cours des premières versions du projet.

Il ne peut donc plus être considéré comme entièrement indépendant du processus exploratoire.

Une évaluation ultérieure sur une population réellement nouvelle serait préférable pour estimer les performances en conditions d'utilisation.

7.4. Disponibilité temporelle des informations

Les variables historiques ont été construites à partir de plusieurs tables.

Avant tout déploiement, il serait indispensable de vérifier que chaque information utilisée était disponible au moment de la décision de crédit.

Cette vérification est essentielle pour écarter une éventuelle fuite temporelle d'information.

7.5. Passage à une décision opérationnelle

Une bonne capacité de discrimination ne suffit pas à définir une politique d'octroi de crédit.

Un usage opérationnel nécessiterait notamment :

- Une calibration suffisamment fiable des probabilités.
- Une politique explicite de choix du seuil de décision.
- Une analyse des coûts associés aux différents types d'erreurs.
- Des contrôles de stabilité, d'explicabilité et d'équité des prédictions.

---

8. CONCLUSION GÉNÉRALE

Ce projet avait pour objectif d'étudier l'influence de l'enrichissement progressif des données sur la prédiction du risque de défaut de crédit, tout en comparant les performances de deux approches de classification supervisée.

L'expérimentation met en évidence une amélioration continue de la ROC-AUC lorsque les informations disponibles sont enrichies.

La régression logistique passe d'une ROC-AUC de **0,5888 à 0,7338**, tandis que LightGBM progresse de **0,5975 à 0,7443**.

Les deux algorithmes bénéficient donc de l'intégration de nouvelles variables.

LightGBM conserve néanmoins un avantage à chacune des cinq étapes et obtient les meilleures performances sur la configuration finale de vingt variables.

L'étude montre également que l'ajout des trois variables `EXT_SOURCE` représente l'amélioration la plus importante de l'ensemble du processus.

Le principal enseignement du projet est ainsi double : la richesse des informations utilisées joue un rôle déterminant dans la prédiction du risque de crédit, et LightGBM exploite ces informations avec une efficacité légèrement supérieure à celle de la régression logistique.

Ces résultats restent ceux d'une expérimentation menée sur un ensemble de validation, et non ceux d'un système bancaire prêt à être déployé.

L'analyse constitue néanmoins une base solide pour envisager des travaux complémentaires portant sur la calibration des probabilités, la stabilité des performances, la prévention des fuites d'information et la définition de règles de décision opérationnelles.

En conclusion, ce projet montre qu'une démarche progressive, rigoureuse et comparative permet de mieux comprendre les facteurs de performance d'un modèle de credit scoring, au-delà de la simple recherche de l'algorithme présentant le score le plus élevé.

Source des résultats

Notebook Jupyter du projet : `Untitled(4).ipynb`.

Données : *Home Credit Default Risk*, Kaggle.

Les performances présentées correspondent aux résultats enregistrés dans le notebook, principalement sur l'ensemble de validation. Aucun résultat d'évaluation complémentaire non exécuté n'a été ajouté.